

머신러닝을 활용한 웹툰의 OSMU 가능성 예측

조규원 · 강필성*

고려대학교 산업경영공학

Prediction of Webtoon's OSMU Possibility with Machine Learning

Gyuwon Cho · Pilsung Kang

Department of Industrial Management Engineering, Korea University

The size of the domestic webtoon market is growing rapidly. The webtoon industry is a representative contents industry. Through the One Source Multi-Use (OSMU) of webtoon contents, attempts to converge with other content industries such as movies and dramas and to create new added value are gradually accelerating. Predicting webtoons with high OSMU potential can contribute to increasing the probability of successful convergence of the content industry in that digital content can be converged between multiple content industries through a single digital content. In this study, 5 machine learning based prediction models were constructed for 1,559 webtoons uploaded to Naver and Daum sites to predict the OSMU possibility of webtoons. In addition, to use webtoon images, 'representative colors' and 'representative sentiment' derived variables were created. As a result of evaluation, it was confirmed that it is possible to construct a predictive model with an accuracy of up to 72%.

Keywords: Machine Learning, One Source Multi-Use, Predictive Modeling, Gradient Boosting Machine, eXplainable AI

1. 서 론

국내 웹툰 시장은 <Figure 1>에서 제시된 바와 같이 2013년 1,500억 원에서 매년 꾸준한 성장을 기록하며 2018년 8,805억 원으로 약 5.8배가량 증가할 것으로 전망되고 있다. 웹툰 시장은 포털 사이트에 게재된 웹툰에 대한 광고료 및 유료웹툰 구매 등으로 발생하는 수익을 기반으로 하는 1차 시장과 웹툰 콘텐츠를 기반으로 영화, 드라마, 도서, 이모티콘, 캐릭터 상품 판매 등으로 부가가치 창출을 통해 수익을 창출하는 2차 시장으로 크게 구분된다(KOCCA, 2015).

초기 웹툰 시장은 1차 시장에 국한되었으나 2003년 강풀의 <순정만화>가 영화, 연극 등으로 재가공되며 One Source Multi-Use(OSMU)의 성공 가능성을 보여주었고, 2014년 윤태호 작가의 웹툰 <미생>이 성공적으로 드라마화되면서 웹툰의 OSMU를 통한 부가가치 창출에 대한 시도가 가속화 되었다(KOCCA,

2012, 2015). 이후 <내부자들>, <신과 함께> 등 웹툰 원작 영화의 흥행 성공이 이어지며, 웹툰의 OSMU를 통한 부가가치 창출에 대한 수요는 영화, 방송산업 등 여러 콘텐츠 산업계 내에서 빠르게 증가하고 있다.

이와 같은 웹툰 시장의 성장 및 OSMU를 통한 부가가치 창출에 대한 수요 증가로 인하여 학계에서는 웹툰의 OSMU에 관한 여러 연구가 이루어져 왔다. 웹툰의 OSMU 방향성과 전략에 관한 연구(Han, 2015)에서는 <와라! 편의점> 사례를 중심으로 웹툰의 OSMU 가능성을 높일 수 있는 전략을 정성적인 분석을 통해 제시하였으며, 웹툰의 흥행 요인 분석 연구(Yang, 2016)에서는 '좋아요수', '평점' 등의 항목이 웹툰의 흥행을 결정하는데 유의한 영향을 준다는 사실을 순서회귀분석 방법을 통해 검증하였다. 그러나 개별 웹툰에 대한 OSMU 가능성 예측 및 정량적인 수치 제공을 시도한 연구는 존재하지 않는 것으로 확인되었다. 따라서 본 연구에서는 네이버, 다음 웹사이트에

제8회 산업융합 활성화 방안 및 사례연구 논문공모전 수상논문.

이 논문은 2019년도 정부의 재원으로 한국연구재단의 지원을 받아 수행된 기초연구사업(NRF 2019R1F1A1060338, NRF-2019R1A4A1024732)의 성과물임. 또한 이 연구는 한국산업기술진흥원의 산업인공지능인력양성사업의 지원을 받아 수행되었음(P0008691).

* 연락저자 : 강필성 교수, 02841 서울시 성북구 안암로 145 고려대학교 산업경영공학부, Tel : 02-3290-3383, Fax : 02-929-5888,

E-mail : pilsung_kang@korea.ac.kr

2019년 12월 31일 접수; 2020년 2월 26일 수정본 접수; 2020년 4월 21일 게재 확정.

게재된 1,559개 웹툰에 대해 ‘평균 추천수’, ‘평균 댓글수’ 등의 관련 정형 데이터와 함께 비정형 데이터인 웹툰 이미지를 함께 활용하는 머신러닝 기반의 예측 모형 구축을 통해 OSMU 가능성을 예측하고 이에 대한 정량적인 수치를 제공하고자 하였다. 또한, 웹툰의 OSMU 가능성을 높이거나 낮게 하는데 주요하게 작용한 요인들의 변수 중요도 및 해당 변수의 유의미한 구간 제시를 통해 융합 활성화의 성공 확률을 높일 수 있는 직접적인 정보를 제공하는 것에 목적을 두었다.




Figure 1. Growth of Domestic Webtoon Market

2. 데이터 수집

현재 웹툰 서비스를 제공하고 있는 웹 사이트는 네이버, 다음, 레진 코믹스, 탑툰 등 매우 다양하다. 이 중 가장 대중적으로 잘 알려져 있는 네이버, 다음 웹 사이트에 연재된 웹툰을 웹 크롤링(Crawling) 기술을 사용해 <Table 1>과 같이 수집했다. 데이터 수집은 2019년 8월 18일 기준으로 두 사이트에 연재된 웹툰 중에서 유료웹툰과 성인웹툰을 제외한 1,559개 웹툰을 수집했으며, 수집한 웹툰 데이터 중 완결 웹툰을 학습 데이터로 미완결 웹툰을 모형의 성능 평가를 위한 평가 데이터로 사용하였다. 추가적으로, 예측 모형의 종속변수인 OSMU 여부에 대한 데이터를 수집하기 위해서는 OSMU의 범위를 먼저 설정할 필요가 있었다. 본 연구에서는 영화, 드라마, 도서출판, 이모티콘 총 4개 분야에 대해서 OSMU가 진행된 웹툰을 대상으로 선정했으며 수집했던 모든 웹툰에 대해서 OSMU 여부를 파악하기 위해 직접 대조 작업을 통해서 라벨링(Labeling) 하는 과정을 거쳤다. OSMU가 진행된 웹툰은 <Table 2>와 같이 전체 웹툰 대비 약 26% 정도로 범주 불균형이 발생하는 상황임을 확인할 수 있었다.

최종적으로 각 웹툰에 대해서 수집한 데이터의 항목은 ‘작가명’, ‘장르’ 등의 범주형 데이터와 ‘평균 추천수’, ‘평균 댓글수’ 등의 수치형 데이터, 비정형 데이터인 ‘웹툰 이미지’를 포함해 <Table 3>과 같은 총 11개 항목을 수집했으며 각 데이터 특성에 맞게 추가적인 전처리 과정을 거쳐 최종 예측 모형의 입력변수로 사용했다.

Table 1. Webtoon Data Collection Results

	Complete	Incomplete	SUM
Naver	433	308	741
Daum	719	99	818
SUM	1,152	407	1,559

Table 2. Number of OSMU Webtoons

	OSMU(O)	OSMU(X)	SUM
Naver	217	524	741
Daum	195	623	818
SUM	412	1,147	1,559

Table 3. Features of Collected Webtoon Data

Collected Feature List					
Title	Author	Site Platform	Genre	Avg. Reply Count	Avg. REC Count
Avg. Star Rating	Serial Period	Episode Count	Webtoon Image	OSMU (O/X)	

3. 데이터 전처리 및 파생변수 생성

3.1 범주형 데이터 전처리

데이터 수집 단계에서 수집한 11개의 데이터 항목 중 수치형 데이터를 제외한 ‘작가명’, ‘장르’, ‘웹툰 이미지’ 항목에 대하여 다음과 같은 전처리를 수행하였다. 먼저 ‘작가명’ 항목은 예측 모형을 위한 변수로 곧바로 사용하기에는 범주가 매우 다양하기 때문에 유의미한 변수로 사용될 가능성이 적다고 판단하여 ‘작가 영향력’ 파생변수를 별도로 생성하였다. ‘작가 영향력’ 변수는 수집한 웹툰 데이터에서 해당 작가가 몇 개의 웹툰 제작에 참여했는지를 수치화한 것이며, 웹툰 작가명의 경우 독특한 필명을 사용하는 경우가 많기 때문에 중복된 이름으로 인한 문제점은 발생하지 않았다. 또한, 스토리 작가와 그림 작가가 따로 있는 경우와 같이 다수의 웹툰 작가가 제작에 참여한 웹툰의 경우 해당 웹툰 제작에 참여한 모든 작가의 작가 영향력을 평균을 내어 사용했다. ‘웹툰 장르’ 항목의 경우 데이터를 수집을 진행했던 네이버, 다음 두 사이트 모두 하나의 웹툰이 다중 장르에 속하는 것으로 분류하고 있었다. 따라서, 수집한 ‘웹툰 장르’ 항목을 단일 범주형 변수로 구성하지 않고 <Figure 2>와 같이 총 18개의 웹툰 장르를 모두 이진 변수화하여 예측 모형의 입력변수로 사용하였다.

The Genre of Webtoons				
Episode	Story	Omnibus	Daily	Comic
Fantasy	Action	Drama	Pure	Thriller
Sports	Emotion	Hitsorical Drama	Oriental Fantasy	Mystery
Knowledge	School	Horror		

Title : Tower of God
Genre : Story, Fantasy

Story	Fantasy	Comic	...	Horror
1	1	0	0	0

Figure 2. Binarization Process of Webtoon Genre Features

3.2 이미지 데이터 전처리

이미지 데이터는 R, G, B 세 개의 색상 정보를 담고 있는 픽셀(pixel)들로 이루어져 있다. 이미지 데이터를 예측 모델을 위한 변수로 사용하기 위한 대표적인 방법으로는 특성 공학(feature engineering)을 통해 이미지 데이터로부터 유의미한 파생변수를 추출하는 방법과 최근 널리 이용되는 합성곱 신경망(convolutional neural networks; CNN)을 통해 이미지에 대한 특징을 추출하여 모델에 적용하는 방법이 있다(Krizhevsky *et al.*, 2017).

합성곱 신경망을 통해 이미지 데이터의 특징을 추출하여 활용하는 방법은 이미지 데이터가 주어졌을 때 별도의 추가 처리 없이 입력 데이터를 학습하는 과정에서 모델의 성능을 높일 수




Figure 3. Process for Creating Derived Variables from Webtoon Image

있는 특징을 학습할 수 있다는 장점이 있으나, 실제 모델이 학습한 특성을 인간이 해석하는 과정에서 어려움이 존재한다. 본 연구에서는 웹툰 이미지에서 출현 빈도가 높은 색상과 해당 색상을 통해 인간이 느낄 수 있는 감정이 OSMU 가능성을 예측하는데 유의미한 변수로 작용할 것이라는 가정을 통해 웹툰 이미지 데이터로부터 <Figure 3>과 같이 세 단계의 전처리 과정을 통해 '대표 색상', '대표 감정'이라는 비교적 해석이 용이한 파생변수를 생성하여 예측 모델의 입력변수로 사용했다.

(1) 개별 이미지에 대한 대표 RGB 값 추출

일반적으로 웹툰은 제작 과정에서 사전에 주요 캐릭터 및 배경에 대한 색상표를 구축하게 된다(Lowellssi and Sian, 2017). 이를 바탕으로 하나의 웹툰을 대표하는 색상은 제작 초기부터 사용되던 색상이 지속적으로 사용될 것이라는 가정을 통해 웹툰의 '대표 색상' 파생변수를 생성하는데 있어 모든 웹툰 이미지를 사용하지 않고 <Figure 4>와 같이 웹툰별 1~3화에 해당하는 이미지만을 사용하여 파생변수를 생성했다.




Figure 4. Details of 3-step Process for Creating Derived Variables

하나의 웹툰은 복수의 이미지 파일로 구성되어 있으므로 웹툰별 대표 색상을 추출하기 위해서 먼저 개별 이미지에 대해 비지도 학습 방법인 K-평균 군집화 방법을 통해 K개의 군집을 생성하고 각각의 군집의 중심에 위치한 RGB 값을 추출하는 과정을 거쳤다(Che, 2008). K-평균 군집화의 경우 사용자가 사전에 군집의 개수 K를 지정해주어야 하며, 이때 지정해준 군집의 개수에 따라 군집화 성능이 달라지기 때문에 적절한 K 값을 설정할 필요가 있다. 일반적으로 군집의 개수를 증가시키더라도 군집화 성능의 향상이 유의미하게 이루어지지 않는 엘보-포인트(elbow-point)를 찾아 K값으로 선정한다. 본 연구에서는 모든 군집에 대해서 수식 (1)과 같이 군집 내 중심 값과 해당 군집 내 모든 값들의 유클리드 거리의 합(sum of squared distances; SSD)을 산출하여 성능 지표로 활용하였다.

$$SSD = \sum_{j=1}^k \sum_{i=1}^n \|x_i^j - c_j\|^2 \quad (1)$$

k : number of clusters

n : number of pixels

c_j : centroid of cluster j

x_i^j : i^{th} pixel in cluster j

전체 1,559개 웹툰의 86,362개 이미지 중 5%의 웹툰 이미지를 랜덤 샘플링(random sampling) 하여 각각의 이미지에 대해서 K값을 1부터 9까지 증가시키면서 K-평균 군집화 진행한 SSD의 변화는 <Figure 5>와 같다. 해당 결과 값은 이미지 별 픽셀 수 차이에 따른 보정을 위해 min-max 스케일링을 추가로 적용 후 평균을 내어 산출하였다. K값 변화에 따른 결과를 보면, $K > 3$ 일 때 군집 개수 증가에도 성능이 향상이 크게 이루어지지 않는 웹툰 이미지의 특성상 흰색, 검은색 등의 색상이 다수를 차지하고 있는 경우가 많기 때문에 대부분의 이미지에 대해서 대표 RGB 값이 유사해지는 문제가 발생한다. 따라서 적정 K 값을 조금 더 상향시켜 6으로 선정하고 <Figure 6>과 같이 개별 이미지에 대한 대표 RGB 값 6개씩을 추출하였다.




Figure 5. Clustering Performance Variation with K values

$k = 6$
" " "
6, 9

1-3화 이미지 16121

Image	Color	RGB	Pixel Counts
		[254, 255, 255]	386,472
		[164, 138, 94]	144,803
		[243, 212, 168]	116,954
		[51, 133, 139]	110,624
		[94, 205, 207]	64,584
		[54, 36, 18]	30,783

Figure 6. Example of K-means Clustering for Single Image(K= 6)

(2) 대표 RGB 값에 대한 KS 기본색 추출

전체 1,559개 웹툰의 1~3화 이미지 개수는 최소 3개에서 최대 556개로, 앞서 개별 이미지에 대해 6개의 RGB 값을 추출한 것을 고려할 때 하나의 웹툰의 대표 RGB 값의 개수는 18~1,668개로 심한 차이가 발생한다. 또한, RGB 값은 각 채널이 0~255의 이산 값을 가지며, 세 채널의 색상 값의 조합에 따라 16,777,216개의 색상이 존재할 수 있기 때문에 수치형, 범주형 변수로 그대로 사용하는 것은 예측 모형의 변수로 적합하지 않다. 본 연구에서는 개별 이미지로부터 추출한 모든 RGB 값을 국가 색채 표준에 따라 유채색 12색, 무채색 3색으로 이루어진 <Figure 7>의 KS 기본 15색(KSA, 2009)과의 색채 간 거리 계산을 통해 가장 거리가 가까운 기본색으로 매핑(mapping) 하는 전처리 과정을 수행했다. 해당 과정에서 색채 간 거리 계산 시 웹툰의 배경 색상으로 '하양', '검정' 등의 무채색이 자주 사용되는 것을 고려해 유채색과 무채색에 대해서 별도로 분리하여 거리 계산을 수행하였다. 색채 간 거리 측정 방식에는 국제 조명 위원회 (International Commission on Illumination; CIE)에서 제안한 기법인 delta CIE 2000 equation을 통해 측정 했다(Sharma et al., 2005).

Chromatic 12 Colors	Red	Orange	Yellow	Yellow Green
	Green	Blue Green	Blue	Indigo
	Bluish Purple	Reddish Purple	Pink	Brown
Achromatic 3 Colors	White	Grey	Black	

Figure 7. KS Basic 15 Colors

(3) 대표 RGB 값에 대한 감성어휘 추출

본 연구에서는 웹툰의 이미지에 사용된 색상을 통해 인간이 느끼는 감성에 대한 파생변수를 생성하기 위해 이화여대 색채 디자인 연구소의 ‘감성어휘 및 디자인스타일에 따른 단색, 배색 DB’를 활용하였다(Hong *et al.*, 2012). 해당 색채 데이터베이스는 <Figure 8>과 같이 총 678개의 RGB값에 대해 40개의 감성어휘로 분류하고 있다. 전처리 1단계에서 추출한 개별 이미지에 대한 6개의 대표 RGB값과 감성어휘 색채 데이터베이스에 존재하는 RGB값과의 색채 간 거리 계산을 통해 가장 거리가 가까운 색상에 해당하는 감성어휘를 추출하였으며 색채 간 거리 측정 방식은 대표 색상 추출 시 사용했던 delta CIE 2000 equation을 동일하게 사용하였다.

Emotional Vocab Monochrome / Color Scheme DB			
1	Strong	21	Fascinate
2	Grand	22	Splendid
3	Deep	23	Traditional
4	Masculine	24	Retro
5	Modern	25	Emotional
6	Simple	26	Romantic
7	Moderate	27	Cute
8	Dapper	28	Beautiful
9	Distingue	29	Casual
10	Intellectual	30	Tripping
11	Dignified	31	Sparky
12	Classical	32	Dynamic
13	Chic	33	Amusing
14	Unique	34	Natural
15	Exceptional	35	Eco-Friendly
16	Mystic	36	Light
17	Exotic	37	Fresh
18	High-Tech	38	Bright
19	Cold	39	Wishful
20	Sexy	40	Pure

Figure 8. Color-Emotional Words Mapping Database

3.3 파생변수 생성

전처리 1단계를 거쳐 추출된 대표 RGB값에 대해 전처리 2 단계에서 색채 간 거리 계산을 통해 KS 기본색(유채색/무채색)과 감성어휘가 매핑 된 결과는 <Figure 9>와 같다. 최종적으로 웹툰별로 해당 웹툰의 개별 이미지에 대해 추출한 대표 RGB값에 매핑 된 유채색, 무채색, 감성어휘의 빈도수를 측정하여 빈도수 기준 상위 3개의 유채색, 상위 1개의 무채색, 상위 3개의 감성어휘를 <Figure 4>와 같이 ‘대표 유채색 1~3’, ‘대표 무채색’, ‘대표 감성 1~3’이라는 파생변수로 생성하여 예측 모형의 입력변수로 사용하였다.




Figure 9. Example of Image Preprocessing Step-2 Output

4. 실험 및 평가

본 연구에서는 웹 크롤링을 활용해 수집한 1,559개 웹툰의 데이터와 전처리를 거쳐 생성한 파생변수를 포함하여 최종 32개의 변수를 <Figure 10>과 같이 예측 모형의 입력변수로 사용하였다.

Input Variable		ML Model	Target Variable OSMU(O/X)
1	Site Platform		
2	Serial Period		
3	Avg.Star Rating		
4	Episode Count		
5	Avg.REC Count		
6	Avg.Reply Count		
7	Author Power		
8 ~ 25	Genre 1 ~ 18		
26 ~ 28	REP.Ch.Col 1 ~ 3		
29	REPAch.Col		
30 ~ 32	REPEmo 1 ~ 3		

Figure 10. Input and Target Variables for Predictive Model

4.1 예측 모형 구축

웹툰의 ‘OSMU 여부’는 0 또는 1의 값을 가지는 이진 범주에 해당한다. 본 연구에서는 일반화 선형 모형(generalize linear model) 중 종속변수가 범주형일 경우 사용 가능한 로지스틱 회귀모형과 함께 의사결정트리 기반의 앙상블 방법론(ensemble methods)을 적용한 모형인 랜덤 포레스트(random forest), 아다 부스트(ada-boost), 그래디언트 부스팅(gradient boosting machine; GBM), XG 부스트(xgboost) 총 5개의 모형을 구축하여 실험을 진행하였다. 모형의 예측 성능은 사용자 설정 값인 하이퍼파라미터(hyperparameter)에 따라서 달라질 수 있기 때문에 모형별 최적의 하이퍼파라미터 탐색이 필요하다. 본 연구에서는 분류 정밀도(precision)와 재현율(recall)을 함께 고려한 F1 score를 기준으로 그리드 서치(grid-search)를 통해 최적 하이퍼파라미터를 선정하였다.

예측 모형 훈련을 위해 전체 1,559개의 웹툰 중 완결 웹툰 1,152개를 훈련 데이터로 미완결 웹툰 407개를 평가 데이터로 사용하였다. 훈련 데이터의 수가 충분치 않음을 고려해 최적 하이퍼파라미터 선정을 위한 별도의 검증 데이터를 구성하지 않고, k-겹 교차 검증(k-fold cross-validation) 기법을 통해 훈련된 모형의 성능 검증을 진행하였으며, k = 10으로 선정하였다. 또한, 종속변수인 ‘OSMU 여부’의 경우 실제 OSMU가 진행된 웹툰이 전체 데이터에서 약 26% 정도로 범주 불균형 문제로 인한 학습 성능 저하를 방지하기 위해 범주 개수가 적은 OSMU가 진행된 웹툰에 대해서 랜덤 업샘플링(random upsampling)을 통해 OSMU가 진행되지 않은 웹툰과의 개수를 동일하게 맞추어 학습을 진행하였다.

4.2 모형 성능 평가

모형별 최적 하이퍼파라미터 탐색을 거쳐 최종 구축된 5개 모형을 통해 평가 데이터인 미완결 웹툰의 OSMU 가능성 예측 성능을 평가한 결과는 <Table 4>와 같다. 각 모형의 예측 결과에 대해서 <Table 4>의 6개의 평가 척도를 통해 성능 평가를 진행하였다. 해당 6개의 척도는 분류 문제에 대한 주요 성능 평가 지표로, <Table 5>의 정오 행렬(confusion matrix)을 기반으로 산출 가능하다. 종속변수의 범주 간 불균형을 보정한 Balanced Accuracy 및 교차 검증 시 성능 평가의 기준이었던 F1-score, Recall, AUC 총 4개의 척도에서 그래디언트 부스팅 모형이 가장 좋은 성능을 보여주었으며, Precision과 Accuracy의 측면에서는 로지스틱 회귀모형이 가장 높은 정확도를 보여주었다.

또한, 웹툰 이미지에 사용된 색상으로부터 추출한 파생변수를 사용했을 때의 예측 성능이 해당 변수를 제외했을 때와 비교했을 때 실험을 진행했던 5개의 모형 중 4개 모형에서 더 높게 나타나는 것을 볼 수 있다. 이를 통해 본 논문에서 사전에 가정한 웹툰 이미지에 사용된 색상 및 색상으로부터 추출한 감성이 OSMU 가능성 예측 과정에서 유의하게 작용했음을 확인할 수 있었다.

<Table 6>에는 2019년에 영화진흥위원회에서 발간된 한국 상업영화 수익성에 대한 자료이며 2013년부터 2017년까지 개봉된 한국영화의 총 편수와 손익분기점을 상회한 영화의 수, 그리고 그 비율이 나타나 있다. 이에 따르면 영화콘텐츠의 경우 개봉한 영화 중 27.14%~40.54%만의 영화가 손익분기점을 넘는 것으로 나타났다. 상업영화의 경우 영화 제작을 결정하는 시점에서 손익분기점을 넘을 것으로 기대되는 영화만이 영화 제작이 이루어지게 되는 것이 일반적이다. 그러나 실제로 확인된 상업영화의 손익분기점 상회 비율이 최대 40%대임을 고려할 때, 나머지 상업영화에 대해서는 예측을 실패한 것으로 판단할 수 있다. 이러한 관점에서 본 연구에서 제안하는 예측 모형의 경우 최대 55.26%의 Precision (OSMU로 예측한 웹툰이 실제로 OSMU로 확장되는 비율)을 나타냄으로써 상업영화 손익분기점 상회 비율에 대한 Precision(손익분기점을 넘을 것으로 예측한 영화가 실제로 손익분기점을 상회할 비율)에 비해 상대적으로 높은 예측 정확도를 나타낸다고 볼 수 있다.

Table 4. Evaluation Results for Test Data

Model	F1-Score	Precision	Recall	Balanced Accuracy	Accuracy	AUC
Logistic Regression	0.4941	0.5526	0.4468	0.6691	0.7887*	0.6849
Logistic Regression(w/o color)	0.4746	0.4015	0.5638	0.6605	0.6953	0.7123
Random Forest	0.4960	0.3974	0.6596	0.6796	0.6904	0.7159
Random Forest(w/o color)	0.4690	0.4015	0.5638	0.6557	0.7052	0.6850
AdaBoost	0.4074	0.4853	0.3511	0.6196	0.7641	0.7216
AdaBoost(w/o color)	0.4459	0.5556*	0.3723	0.6414	0.7862	0.7445
GBM	0.5528*	0.4474	0.7234*	0.7275*	0.7297	0.7536*
GBM(w/o color)	0.4878	0.4505	0.5319	0.6685	0.7420	0.7076
XGBoost	0.5238	0.4741	0.5851	0.6951	0.7543	0.7447
XGBoost(w/o color)	0.5024	0.4505	0.5319	0.6685	0.7420	0.7347

Table 5. Confusion Matrix

	Predicted OSMU (Positive)	Predicted OSMU (Negative)
Actual OSMU (Positive)	TP	FN
Actual OSMU (Negative)	FP	TN

*TP : The actual number of webtoons with OSMU applied among webtoons that the model predicts as high OSMU possible webtoons

*FN : The actual number of webtoons with OSMU applied among webtoons that the model predicts as low OSMU possible webtoons

*FP : The number of webtoons that the model predicts as highly likely OSMU webtoons without actual OSMU progression

*TN : The number of webtoons that the model predicts as unlikely OSMU webtoons without actual OSMU progression

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (3)$$

$$Balanced\ Accuracy = \frac{1}{2} \times \left(\frac{TP}{TP + FN} + \frac{TN}{FP + TN} \right) \quad (4)$$

$$Precision = \frac{TP}{TP + FP}, \quad Recall = \frac{TP}{TP + FN} \quad (5)$$

$$F1 - Score = 2 \times \frac{Precision \times Recall}{Precision + Recall} \quad (6)$$

Table 6. Profitability Analysis of Korean Commercial Films 2013~17

	2013	2014	2015	2016	2017
Number of Films To Be Analyzed	63	67	70	33	37
Number of Films Above Break Even Point	21	22	19	13	15
Ratio of Films Above Break Even Point	33%	33%	27%	39%	41%

4.3 변수 중요도

네 가지 성능 평가 지표에서 가장 높은 정확도를 나타낸 그라디언트 부스팅 모델을 포함한 의사결정트리 기반의 예측 모형은 <Figure 11>과 같이 학습 데이터의 분류 성능을 높이는 데 주요하게 작용한 입력변수들의 중요도(feature importance)를 측정하는 것이 가능하다. 전체 32개의 입력변수에 대해 변수 중요도를 min-max 스케일링을 통해 살펴본 결과 웹툰의 인기도를 파악해 볼 수 있는 ‘평균 댓글수’, ‘평균 추천수’ 등의 입력변수의 중요도가 높게 나타났으며, 범주형 데이터 전처리 및 이미지 데이터 전처리를 통해 생성한 파생변수인 ‘작가 영향력’, ‘대표 감성3’, ‘대표 유채색’ 변수가 변수 중요도 기준 상위 존재하는 것을 확인할 수 있었다.

또한, 그라디언트 부스팅 모델을 포함하여 본 연구에서 구축했던 의사결정트리 기반의 모형인 랜덤 포레스트, 아다부스트, XG 부스트 모형 전체의 평균 변수 중요도를 <Figure 11>을 통해 살펴볼 때, 모형별 변수 중요도의 편차가 크지 않았고, 전처리 과정을 통해 추가로 생성한 ‘대표 감성’, ‘대표 유채색’ 관련 파생변수가 모든 모형에서 평균적으로 상위 존재하는 것을 통해, 본 연구에서 진행한 파생변수 생성 과정이 유의했다고 판단할 수 있다.




Figure 11. Feature Importance

5. 예측 결과 분석

최종 선정한 예측 모형인 그라디언트 부스팅 모형의 경우 모형이 예측한 결과에 대해서 각각의 입력변수가 미친 영향력을 전역적으로 해석하기 어려운 블랙박스(black-box) 모형에 해당한다. 앞서 살펴본 변수 중요도를 통해 부스팅 트리 분할 시 예측 모형의 성능을 높이는 데 주요하게 작용한 변수들을 파악할 수는 있으나 변수 중요도를 통해서만 개별 변수의 값의 변화 또는 차이가 OSMU 여부를 결정하는 데 있어 미치는 영향력을 파악하는 것은 불가능하다는 단점이 있다. 최근 이러한 블랙박스 모형의 예측 결과에 대한 해석을 위해 SHAP(SHapley Additive exPlanations) (Lundberg *et al.*, 2017), pdp(partial dependence plots)(Greenwell *et al.*, 2017), LIME(Local Interpretable Model-agnostic Explanations) (Ribeiro *et al.*, 2016)과 같은 여러 연구가 이루어지고 있으며, 본 연구에서는 이 중 LIME 기법을 이용하여 예측 모형의 스코어에 각각의 입력변수가 미치는 영향력에 대한 해석을 진행했다.

분석을 위해 사용한 LIME 기법은 사전 학습된 예측 모형을 통해 추출한 개별 평가 데이터의 예측 값을 재예측 하는 단순한 선형 모형을 지역적으로 적합 시키는 것을 통해 개별 평가 데이터의 예측 결과에 미치는 영향력이 큰 입력변수의 구간 또는 범주를 <Figure 12>와 같이 찾을 수 있다. 예를 들어, 모형의 예측 결과 스코어가 가장 높았던 <Figure 12>의 흥끼 작가의 <노곤하개> 웹툰의 경우 실제 ‘평균 추천수=37,132’, ‘평균 별점=9.98’의 변수 값이 LIME 기법을 통해 ‘평균 추천수 > 7,062’, ‘평균 댓글수 > 3,087’ 등의 구간에 속하는지 여부를 나타내는 비교적 해석이 가능한 이진 변수로 변환되어 모형의 예측 값인 0.83을 예측하는 선형 모형으로 재적합 되는 과정을 거치게 된다. 이 과정에서 각 이진 변수에 대한 가중치를 통해 개별 평가 데이터에 대한 해당 입력변수의 부분적인 영향력을 추정해볼 수 있다. 모형의 예측 결과 가장 스코어가 낮았던 손제호/제나 작가의 <일렉시드> 웹툰의 경우 LIME 기법을 적용한 결과, 예측 스코어가 가장 높았던 <노곤하개> 웹툰의 가중치와는 반대로 웹툰의 인기도와 관련된 ‘평균 추천수 > 7,062’ 변수가 음의 가중치를 갖고 ‘평균 별점 ≤ 9.4’ 변수가 양의 가중치를 갖는 것을 확인할 수 있었다.




Figure 12. Estimation of Feature Importance with LIME

본 연구에서는 개별 웹툰에 대한 지역적인 해석을 통해 LIME 기법을 통해 추출 입력변수들의 구간 및 범주에 대한 변수 가중치와 모형의 실제 예측 스코어 간의 상관관계를 살펴 보기 위해 추가적인 분석을 진행하였다. 그라디언트 부스팅 모형의 예측 결과 스코어 기준 상·하위 10%에 속하는 웹툰을 각각 40개씩 추출하여 LIME 기법을 적용한 결과, 추출된 개별 웹툰에 대해서 양수 값의 가중치를 가지는 상위 10개의 변수 구간 및 범주를 빈도수 기준으로 살펴본 결과는 <Table 7>과 같다.

모형의 예측 스코어가 높은 상위 10%의 웹툰에 영향을 미치는 입력변수의 구간 및 범주를 살펴본 결과 ‘평균 별점 > 9.9’, ‘평균 댓글수 > 3,087’, ‘평균 추천수 > 7,062’ 일 때 예측 스코어가 높게 나타나는 경우가 많았으며 하위 10%의 웹툰의 경우 ‘작가 영향력 < 2’ 인 경우 모형의 예측 스코어가 낮게 예측되는 경우가 많았다. 또한, 앞서 살펴본 변수 중요도 기준 상위에 있었던 변수인 ‘대표 감성3’과 ‘대표 유채색3’의 경우 각각 ‘대표 감성3 = 하이테크’한 경우와 ‘대표 유채색3 = 노랑’일 경우 웹툰의 OSMU 가능성이 낮게 예측되는 경우가 많았다. 특히 ‘평균 추천수’와 ‘작가 영향력’, ‘대표 무채색’ 등의 변수의 경우 상위 10% 웹툰과 하위 10% 웹툰과의 구분이 명확하게 이루어지는 것을 확인할 수 있었다. 추가적으로, 예측 모형이 OSMU 가능성이 높은 웹툰으로 판단한 연재 사이트별 상위 10% 웹툰은 <Appendix>의 <Table A1>을 통해 확인할 수 있도록 하였다.

Table 7. Variable Segment and Category Analysis with LIME

	Range & Category	Freq.
Top 10%	Avg.Star Rating > 9.9	26
	Avg.Reply Count > 3,087	26
	Avg.REC Count > 7,062	25
	Author Power >= 2	24
	REP.Ach.Col = White	21
	Episode Count > 69	19
	REP.Ch.Col 2 != Yellow	19
	REP.Emo 2 != Grand	19
	Serial Period > 414.8	17
	Site Platform = Naver	16
Bottom 10%	REP.Emo 2 = Grand	35
	REP.Emo 3 = High-Teh	35
	Author Power <= 2	33
	Genre-Story = 1	30
	REP.Ch.Col 3 = Yellow	30
	Avg.Reply Count < 340, Avg.Reply Count >= 3,087	29
	REP.Ch.Col 2 = Blue Green	29
	Avg.REC Count < 7,062	25
	REP.Emo 1 = Modern	24
	REP.Ach.Col != White	23

6. 결 론

본 연구에서는 OSMU 가능성이 높은 웹툰을 예측하는 머신러닝 기반의 예측 모형을 구축하였다. 네이버, 다음에서 수집한 1,559개의 웹툰에 대해서 완결 웹툰을 훈련 데이터로 미완결 웹툰을 평가 데이터로 하여 총 5개의 예측 모형에 대한 실험 결과 F1-score와 균형 정확도가 가장 높은 그라디언트 부스팅 모형을 최종 예측 모형으로 선정하였으며 최대 72% 정확도를 확인할 수 있었다. 또한, 웹툰 관련 정형 데이터와 더불어 비정형 데이터인 웹툰 이미지에 대해서 추가적인 전처리를 통해 생성한 파생변수인 웹툰의 대표 색상을 통해 느끼는 ‘대표 감성’ 및 ‘대표 색상’ 관련 변수가 그라디언트 부스팅 모형의 변수 중요도 기준 상위에 위치하는 것을 통해 파생변수 생성 과정의 타당성을 확인하였다. 웹툰의 OSMU 가능성 예측은 영화, 드라마, 도서출판 및 이모티콘으로 재생산될 가능성이 높은 웹툰에 대한 정량적인 수치 정보 제공을 통해 OSMU 가능성이 높은 웹툰을 우선적으로 선별 가능하다는 점에서 웹툰의 OSMU를 통한 콘텐츠 산업 간 융합 활성화의 성공 확률을 높이는 방안으로써 활용될 수 있을 것이다.

참고문헌

- Chen, T. W., Chen, Y. L., and Chien, S. Y. (2008), Fast image segmentation based on K-means clustering with histograms in HSV color space, *In Proceedings of the 2008 IEEE 10th Workshop on Multimedia Signal Processing, MMSP 2008*.
- Greenwell, B. M. (2017), pdp : An R package for constructing partial dependence plots, *R Journal*, 9(1), 421-436.
- Han, H. K. (2015), A Study on Webtoons OSMU Strategy for Enhanced Profitability : Focused on the Case of Welcome to convenience Store, *The Korean Journal of animation*, 11(3), 151-171.
- Hong, J. I., Lee, Y. J., and Kim, S. J. (2012), A Study on the single color for the industrial design -focus on the single color pursuant to the emotional words-, *Journal of Korea Society of Color, Studies*, 26(2), 61-74.
- KOCCA(Korea Creative Content Agency)(2012), Status and characteristics of webtoons and webtoon-based OSMU activation status, 5-6.
- KOCCA(Korea Creative Content Agency)(2015), Survey on current status of webtoon industry, 22-23, 81-82.
- KSA(Korean Standards Association)(2009), Public Design Color Standard Guide, 8-9.
- Krizhevsky, A., Sutskever, I., and Hinton, G. E. (2017), ImageNet classification with deep convolutional neural networks, *Communications of the ACM*, 84-90.
- Lowellssi and Sian (2017), Making Webtoon By Photoshop SAI Sketchup, Gilbut Publishing, Seoul, Korea, 125-140.
- Lundberg, S. M. and Lee, S. I. (2017), A unified approach to interpreting model predictions, *In Advances in Neural Information Processing Systems*, 4768-4777.
- Ribeiro, M. T., Singh, S., and Guestrin, C. (2016), Why should i trust you?, Explaining the predictions of any classifier, *In Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 1135-1144.

Sharma, G., Wu, W., and Dalal, E. N. (2005), The CIEDE2000 color-difference formula : Implementation notes, supplementary test data, and mathematical observations, *Color Research and Application*, **30**(1), 21-30.

Yang, J. H., Lee, J. Y., and Lee, S. H. (2016), Factors Affecting Webtoon's Success : An Empirical Study, *Journal of The Korea Contents Association*, **16**(5), 194-204.

저자소개

조규원 : 홍익대학교 경영학과에서 2018년 학사학위를 취득하

였다. 현재는 고려대학교 산업경영공학부에서 석사과정으로 재학 중이다. 연구 분야는 자연어 처리 및 기계학습 알고리즘 개발이다.

강필성 : 서울대학교 산업공학과에서 2003년 학사, 2010년 박사학위를 취득하였다. 이후 현대카드 과장, 서울과학기술대학교 조교수로 근무하였으며, 현재는 고려대학교 산업경영공학부 부교수로 재직 중이다. 연구 분야는 정형 및 비정형 데이터를 활용한 데이터마이닝 및 기계학습 알고리즘 개발 및 제조/IT/공공분야 응용이다.

<Appendix>

Table A1. List of Top 10% Webtoons with High OSMU Possibility

Rank	Naver	Score	Daum	Score
1	Nogonhagae	0.8323	I'm Mother	0.7289
2	Borthers are Still Peaceful Today	0.8315	Premature Taste	0.6582
3	Penguin loves Mev	0.7992	Grazing	0.5949
4	It's Cheep Cheolima Mart	0.7921	Dings Fat	0.5914
5	The Darkness is Scary Tonight	0.7624	Similar Science Inquiry Area	0.5906
6	About Death	0.7523	Omurice Jam Jam	0.5616
7	Born Nerds	0.7503	Cude Diary	0.5587
8	Welcome To Room 305	0.7445	Colored Melancholy	0.5424
9	Mojo's Diary	0.7358	Hell Temple	0.5307
10	Prestigious Private Jungle High School	0.7295		
11	My girlfriend is a man of man	0.7253		
12	This is also a friend	0.7094		
13	Didn't Laguh Gag School Season 1~2	0.7085		
14	The World is Money & Power	0.7065		
15	Summer Breeze	0.7023		
16	Today's Pure Cartoon	0.6986		
17	San Francisco Gallery	0.6973		
18	Yumi's Cells	0.6735		
19	KUBERA	0.6686		
20	Princess can't Sleep	0.6595		
21	Even At a Young Age	0.6574		
22	Children's Kwon Teacher	0.6417		
23	Liver Falling Together	0.6355		
24	The Sound of Your Heart	0.6096		
25	Cheese in the Trap	0.5900		
26	Girl's World	0.5896		
27	The people I met on the hell	0.5855		
28	30 Minutes of Foot	0.5663		
29	Prince on Cultivator	0.5444		
30	Living with Poodle	0.5443		